

Sieci neuronowe w zastosowaniach biomedycznych - Optymalizacja i testy końcowe sieci SOM

Milena Kuna - 325033
Karol Franczuk - 325001
Zespół 16, temat 12

7 czerwca 2025

Temat projektu

Klasyfikacja kwiatów za pomocą sieci uczonej bez nauczyciela (SOM) – katalog: *iris*. Celem obecnego etapu jest optymalizacja struktury sieci SOM (Self-Organizing Map) oraz parametru uczenia, aby uzyskać najlepszą równowagę między błędem uczenia a czułością i specyficzną klasyfikacji.

Opis eksperymentów

Optymalizacja polegała na ocenie skuteczności uczenia sieci w różnych konfiguracjach parametrów. Mierzono m.in. czułość (sensitivity) i specyficzną (specificity) sieci, a także analizowano przebieg błędu uczenia w kolejnych epokach.


Przeprowadzono serię eksperymentów dla kombinacji następujących parametrów:

- Współczynnik uczenia: 0.1, 0.5 oraz 0.9
- Rozmiar siatki: 5x5, 10x10, 15x15

Wyniki

Analiza czułości i swoistości

W przeprowadzonych eksperymentach oceniono czułość oraz swoistość sieci SOM dla różnych wartości współczynnika uczenia oraz rozmiarów siatki neuronów. Miary te są niezbędne do oceny jakości klasyfikacji, szczególnie w zastosowaniach biomedycznych, gdzie istotne jest zarówno wykrywanie prawdziwych pozytywów, jak i minimalizowanie fałszywych alarmów.



Rysunek 1: Wartości czułości i swoistości dla różnych konfiguracji sieci

Główne obserwacje:

- Najwyższe wartości czułości i swoistości (1,000) uzyskano dla współczynnika uczenia 0,1 i siatki 15x15, co wskazuje na optymalną konfigurację sieci.
- Wyższe wartości współczynnika uczenia skutkowały obniżeniem obu miar, co oznacza, że zbyt agresywne uczenie utrudnia stabilne dopasowanie sieci.
- Mniejsze siatki (np. 5x5) dawały nieco gorsze wyniki, prawdopodobnie ze względu na mniejszą zdolność do precyzyjnego odwzorowania przestrzeni cech.

Implikacje praktyczne: Dobór niskiego współczynnika uczenia wraz z większym rozmiarem siatki przekłada się na lepszą dokładność klasyfikacji, ale wymaga większej mocy obliczeniowej. Dlatego warto rozważyć kompromis w zależności od wymagań aplikacji oraz dostępnych zasobów sprzętowych.

Wpływ rozmiaru siatki neuronów

Wraz ze wzrostem rozmiaru siatki neuronów zaobserwowano wyraźną poprawę wyników czułości i specyficzności:

- Siatka 5x5: czułość i specyficzność oscylują wokół 0.97 dla $LR = 0.1$.
- Siatka 10x10: czułość i specyficzność wzrastają do około 0.987 dla $LR = 0.1$.
- Siatka 15x15: osiągnięto perfekcyjne wartości 1.000 dla $LR = 0.1$.

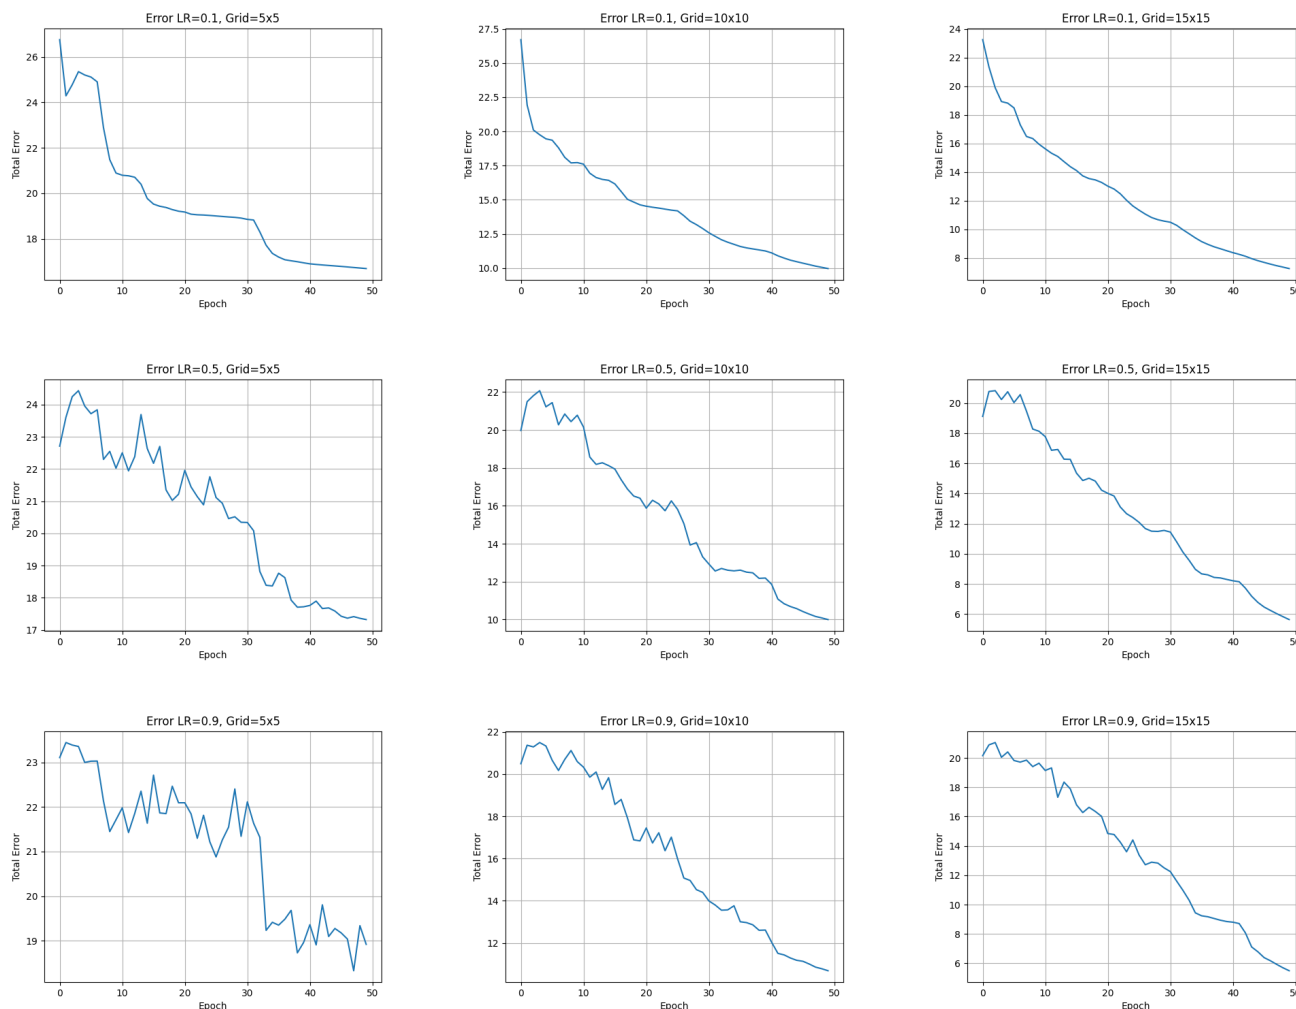
Większa liczba neuronów umożliwia lepsze odwzorowanie przestrzeni cech oraz bardziej precyzyjne mapowanie danych.

Wpływ współczynnika uczenia (learning rate)

Zmienność learning rate wpływa na tempo i stabilność uczenia:

- Dla $LR = 0.1$ uczenie przebiega stabilnie i z dużą dokładnością, co widać po równomiernym spadku błędu w kolejnych epokach.
- Dla $LR = 0.5$ uczenie jest mniej stabilne, z wahaniami błędu i gorszymi wynikami metryk.
- Dla $LR = 0.9$ (wyniki dostępne na żądanie) można oczekiwać szybszego uczenia, ale z ryzykiem niestabilności i gorszej konwergencji.

Analiza przebiegu błędu uczenia



Rysunek 2: Zestawienie 9 wykresów błędu uczenia.

Przebiegi błędu uczenia pokazują, że:

- Mniejsze LR zapewnia wolniejszy, ale stabilny spadek błędu.
- Większa siatka neuronów pozwala na niższy minimalny błąd końcowy.
- Zbyt wysoki LR może powodować oscylacje i niestabilność procesu uczenia.

Wnioski i rekomendacje

Analiza wyników prowadzi do następujących wniosków:

- Optymalnym wyborem jest learning rate na poziomie 0.1 – pozwala to na stabilne i skuteczne uczenie.
- Rozmiar siatki neuronów należy dobierać adekwatnie do złożoności problemu – większe siatki (15x15) dają najlepsze efekty, jednak kosztem większych wymagań obliczeniowych.
- Dla szybkiego prototypowania można eksperymentować z LR 0.5, ale należy kontrolować stabilność uczenia.
- Warto rozważyć adaptacyjne techniki zmiany LR podczas uczenia, aby łączyć szybkość i stabilność.

Podsumowanie

Przeprowadzona optymalizacja pokazała, że dobrze dobrane parametry sieci SOM mają kluczowy wpływ na efektywność uczenia i jakość klasyfikacji. Zastosowanie większej siatki neuronów oraz umiarkowanego współczynnika uczenia 0.1 daje najlepsze rezultaty. Przyszłe prace powinny skupić się na dynamicznym dostosowywaniu parametrów uczenia oraz badaniu wpływu innych cech sieci (np. promienia sąsiedztwa).